

HW 3

Load data

ดาวน์โหลดข้อมูล excel เข้าสู่โปรแกรม R

```
10 # initial parameter
11 sheet_name <- "aus_production"
12 column_name <- c("Quarter", "Cement")
13
14 # load data
15 file_name <- file.choose()
16 df0 <- read_excel(file_name, sheet=sheet_name)
17 df1 <- df0 %>% select(column_name)
18
19 # Convert to tsibble
20 df2 <- df1 %>%
21   mutate(Quarter = yearquarter(Quarter)) %>%
22   as_tsibble(index = Quarter)
```

Data splitting

แบ่ง dataset เป็น fold โดยกำหนด initial fold = 8 และ fold ถัดๆไปจะมีจำนวนข้อมูลเพิ่มขึ้น 1 จาก fold ก่อนหน้า

```
24 # split data
25 train <- df2 %>%
26   filter(year(Quarter) >= 1988) %>%
27   slice(1:(n()-1)) %>%
28   stretch_tsibble(.init = 8, .step=1)
29
```

Model training and forecasting

ทำ model training โดยใช้จำนวนข้อมูล n แล้วทำนายผลของข้อมูลที่ n+1 ผ่าน model แบบต่างๆ

```
33 # train model
34 fit <- train %>%
35   model(
36     Mean = MEAN(Cement),
37     Naive = NAIVE(Cement),
38     SeasonNaive = SNAIVE(Cement),
39     Drift = NAIVE(Cement ~ drift()),
40     ETS = ETS(Cement),
41     ARIMA = ARIMA(Cement)
42   ) %>%
43   forecast(h=1) %>%
44   accuracy(df2)
```

Evaluation

วัดประสิทธิภาพของ model ที่ train มาด้วย metric แบบต่างๆ

```
47 # find best model
48 fit %>%
49   arrange(RMSE)
```

Result

เราจะได้จำนวน **resample** ทั้งหมดคือ **82 fold**

```
30 # total resample
31 train %>% n_keys()

> train %>% n_keys()
[1] 82
```

ค่าเฉลี่ยของแต่ละ evaluation metric จาก โปรแกรม R

```
> # find best model
> fit %>%
+   arrange(RMSE)
# A tibble: 6 x 10
  .model      .type      ME  RMSE  MAE    MPE  MAPE  MASE  RMSSE  ACF1
  <chr>      <chr>    <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1 ETS        Test      3.05  127.  96.6 -0.146  5.28  0.952  0.952  0.0248
2 ARIMA      Test     10.1  140. 110.  0.192  5.87  1.09  1.05 -0.0387
3 SeasonNaive Test     20.7  178. 150.  0.570  8.08  1.48  1.33  0.602
4 Naive      Test      6.18  202. 163. -0.265  8.60  1.61  1.51 -0.288
5 Drift      Test     -4.34  205. 165. -0.827  8.73  1.62  1.54 -0.284
6 Mean      Test     199.  331. 263.  8.41 12.8  2.60  2.48  0.693
```

Conclusion

จากผลการทดสอบพบว่า โมเดลที่ดีที่สุดคือ **ETS** โดยให้ค่า RMSE อยู่ที 126.94 ดังนั้นการทำ forecasting สำหรับ dataset **aus_production** เพื่อทำนายข้อมูล Cement โดยการแบ่ง dataset ด้วยวิธี TS cross validation โมเดลที่ดีที่สุดจากการทดสอบคือ **ETS**